Paper Database Assistant

A browser-based tool for **batch PDF downloading** and **LLM-powered data extraction** from research papers. Runs entirely in your browser -- no backend server needed.

一个基于浏览器的工具，用于**批量下载论文 PDF** 和 **LLM 驱动的结构化数据提取**。完全在浏览器中运行，无需后端服务器。

Python 3.8+ License MIT

Overview / 概述

This tool generates a self-contained HTML page with two modules:

本工具生成一个独立的 HTML 页面，包含两个模块：

Module / 模块	Purpose / 用途	How it works / 工作方式
PDF Download	Batch download papers via DOI / 通过 DOI 批量下载论文	Opens PDF links in browser tabs / 在浏览器标签页中打开 PDF 链接
Feature Extraction	Extract structured data using LLM / 使用大模型提取结构化数据	Renders PDF as images in-browser, sends to Gemini / OpenRouter API / 在浏览器中将 PDF 渲染为图片，发送至 API

The extraction module is **prompt-driven and fully customizable** -- while the default prompts target perovskite solar cell parameters, you can modify them to extract any structured data from any type of paper.

提取模块**完全由 Prompt 驱动、可自定义** —— 默认 Prompt 针对钙钛矿太阳能电池参数，但你可以修改 Prompt 来从任何类型的论文中提取任何结构化数据。

Quick Start / 快速开始

```
# 1. Generate the HTML tool page / 生成 HTML 工具页面
python generate_assistant_page.py

# 2. Open in Chrome / 在 Chrome 中打开
#    Auto-opens on Windows / Windows 下会自动打开
#    File: ./downloaded_pdfs/paper_assistant.html
```

Requirements / 环境要求：

- Python 3.8+（only for generating HTML / 仅用于生成 HTML 页面，不需要额外依赖包）
- Chrome browser + Internet connection（for PDF.js CDN & API calls / 用于 PDF.js 和 API 调用）

Module 1: PDF Download / 模块一：PDF 下载

Batch-download research paper PDFs by opening them in browser tabs.
通过在浏览器标签页中依次打开链接来批量下载论文 PDF。

Setup / 准备

Prepare a DOI list file (default: `non_first_tier_dois_2020_2026.txt`):

准备一个 DOI 列表文件（默认：`non_first_tier_dois_2020_2026.txt`），格式如下：

```
1. https://doi.org/10.1002/aenm.202400012
2. https://doi.org/10.1021/acs.jpclett.4c00001
3. https://doi.org/10.1016/j.joule.2024.01.001
...
```

Usage / 使用步骤

1. Open `paper_assistant.html` in Chrome / 在 Chrome 中打开生成的页面
2. Make sure you are on **campus network** or **institutional VPN** / 确保在**校园网**或已连接**机构 VPN**
3. Configure / 配置参数：
   - **Batch size**: PDFs per batch, recommend 5-10 / 每批数量，建议 5-10
   - **Interval**: delay between tabs, recommend 3s / 打开间隔，建议 3 秒
4. Click **Start Batch** / 点击 **Start Batch** 开始批量打开
5. If CAPTCHA appears, complete it manually, then click **Resume** / 遇到验证码手动完成后点 **Resume** 继续
6. Use **Filter** buttons to view by publisher or status / 使用筛选按钮按出版商或状态过滤

Supported Publishers / 支持的出版商

Publisher	Direct PDF / 直链下载	Notes / 备注
Wiley	Yes	`/pdfdirect/` URL
ACS	Yes	`/pdf/` URL
Science	Yes	`/pdf/` URL
Elsevier	No	Opens DOI page, download manually / 打开 DOI 页面，需手动下载
Nature	No	Opens DOI page, download manually / 打开 DOI 页面，需手动下载

> Progress is saved to `localStorage` -- you can close and reopen without losing progress.
>
> 进度保存在浏览器 `localStorage` 中，关闭页面后重新打开不会丢失进度。

Module 2: Feature Extraction / 模块二：特征提取

Extract structured data from PDF papers using multimodal LLM.

使用多模态大模型从 PDF 论文中提取结构化数据。

How It Works / 工作原理

```
PDF file (local / 本地文件)
    |  [PDF.js renders in browser / 浏览器中渲染]
    v
Page images (JPEG base64 / 页面图片)
    |  [fetch() to API / 发送至 API]
    v
Google Gemini / OpenRouter
    |  [JSON response / 返回 JSON]
    v
Structured data table + CSV export / 结构化数据表格 + CSV 导出
```

Everything runs client-side. Your API key is sent only to the API provider, never to any third party.

所有处理在浏览器端完成。API Key 仅发送给你选择的 API 提供商，不经过任何第三方。

Step-by-Step / 使用步骤

Step 1: Configure API / 配置 API

Setting / 设置	Description / 说明	Default / 默认值
Provider	Google Gemini or OpenRouter / 选择 API 提供商	Google
API Key	Your own key / 你自己的密钥（Google AI Studio 或 OpenRouter）	--
Model	Model name / 模型名称（切换 Provider 时自动调整前缀）	`gemini-2.5-flash`
Image DPI	PDF rendering resolution / PDF 渲染分辨率	200
Max Pages	Max pages per PDF / 每篇论文最大处理页数	30
Delay	Seconds between API calls / API 调用间隔秒数	5
Max Retries	Retry on errors / 错误重试次数	3

> Settings are auto-saved to `localStorage` (including API key -- purely local).
>
> 设置会自动保存到浏览器 `localStorage` （包括 API Key，纯本地存储）。

Step 2: Customize Prompts (Optional) / 自定义 Prompt（可选）

Click **Show / Hide** in the Prompts panel:

点击 Prompts 面板中的 **Show / Hide** 展开：

- **System Prompt**: Defines the LLM's role and extraction rules / 定义大模型角色和提取规则
- **User Prompt**: Specifies the output JSON format and fields / 指定输出 JSON 格式和字段

Default prompts are pre-filled in a **dimmed style** as a writing reference. Click to edit -- text brightens. Click **Reset Defaults** to restore.

默认 Prompt 以**虚化样式**预填充，作为编写参考。点击编辑时文字变亮。点击 **Reset Defaults** 可恢复默认。

To adapt for a different domain / 适配到其他领域：

1. Modify System Prompt for your domain / 修改 System Prompt 描述你的数据领域
2. Modify User Prompt to define your JSON schema / 修改 User Prompt 定义你需要的 JSON 输出格式
3. Results table and CSV will automatically adapt / 结果表格和 CSV 导出会自动适配返回的字段

Example -- adapting for battery research / 示例 —— 适配锂电池研究：

```
System Prompt (excerpt):
You are an expert data extractor for lithium-ion battery research.
Extract cathode material, anode material, electrolyte composition,
cycle life, capacity retention, C-rate...

User Prompt (excerpt):
Return a JSON:
{
  "devices": [{
    "cathode_material": "LiFePO4",
    "capacity_mAh_g": 165,
    "cycle_life": 2000,
    ...
  }]
}
```

Step 3: Select PDF Files / 选择 PDF 文件

Two options / 两种方式：

- **Select Files**: Pick individual PDFs / 选择单个文件
- **Select Folder**: Pick an entire folder (e.g. `downloaded_pdfs/`) / 选择整个文件夹（如 `downloaded_pdfs/` ）

Step 4: Run Extraction / 运行提取

1. Click **Start Extraction** / 点击 **Start Extraction** 开始
2. Monitor progress / 监控进度：
   - **Stat cards**: Files / Done / Errors / Entries / 统计卡片
   - **Progress bar**: overall completion / 总进度条
   - **File list**: per-file status / 每个文件的状态
   - **Processing Log**: timestamped details / 带时间戳的详细日志
3. Click **Pause** to stop after current file / 点击 **Pause** 在当前文件处理完后暂停

Step 5: Export Results / 导出结果

- **Results table** dynamically shows all fields returned by the LLM / 结果表格动态展示 LLM 返回的所有字段

- Click **Export CSV** to download / 点击 **Export CSV** 下载 CSV 文件（UTF-8 with BOM，Excel 兼容）
- Click **Clear Results** to start fresh / 点击 **Clear Results** 清空重来

Error Handling / 错误处理

Scenario / 场景	Behavior / 行为
API rate limit (429)	Auto-retry with exponential backoff / 指数退避自动重试
Empty response / 空响应	Retry up to max retries / 重试至最大次数
JSON parse failure / JSON 解析失败	Multiple repair strategies (brace matching, trailing comma fix, truncation repair) / 多种修复策略
Non-PDF file selected / 选择了非 PDF 文件	Automatically filtered out / 自动过滤

Project Structure / 项目结构

```
paper-database/
├── generate_assistant_page.py   # Generates combined HTML tool / 生成合并版 HTML 工具
├── generate_download_page.py    # Original download-only generator / 原始仅下载版生成器
├── extract_features_gemini.py   # Standalone Python extraction / 独立 Python 提取脚本
├── check_experimental.py        # Pre-filter (absorbed into extraction) / 预筛选（已整合进提取）
├── non_first_tier_dois_2020_2026.txt  # DOI list input / DOI 列表输入
├── downloaded_pdfs/
│   ├── paper_assistant.html     # >>> Generated tool (open in Chrome) / 生成的工具（用 Chrome 打开）
│   └── *.pdf                    # Downloaded papers / 下载的论文
└── ...
```

FAQ / 常见问题

Q: Do I need Python packages to use the HTML page? / 使用 HTML 页面需要安装 Python 包吗?

No. Python is only for generating the HTML. The page itself is self-contained (PDF.js loaded from CDN).

不需要。Python 仅用于生成 HTML 文件。页面本身是自包含的（PDF.js 从 CDN 加载）。

Q: Is my API key safe? / 我的 API Key 安全吗?

Yes. The key is stored in your browser's `localStorage` and sent only to Google / OpenRouter via HTTPS. No intermediary.

安全。密钥仅存储在浏览器 `localStorage` 中，通过 HTTPS 直接发送给 Google / OpenRouter，不经过任何中间方。

Q: Can I use models other than Gemini? / 可以用 Gemini 以外的模型吗?

Yes. With OpenRouter you can use any supported model (e.g. `anthropic/claude-sonnet-4`, `openai/gpt-4o`). Just type the model name.

可以。使用 OpenRouter 时可选择其支持的任何模型（如 `anthropic/claude-sonnet-4` 、 `openai/gpt-4o` ），在 Model 栏输入即可。

Q: What if a paper has no experimental section? / 论文没有实验部分怎么办?

The extraction prompt handles this gracefully -- returns an empty `devices` array with an explanation in `paper_notes`.

提取 Prompt 会优雅处理 —— 返回空的 `devices` 数组，并在 `paper_notes` 中给出说明。

Q: How do I change the DOI list file? / 如何更换 DOI 列表文件?

Edit `DOI_LIST_FILE` at the top of `generate_assistant_page.py`, then re-run.

修改 `generate_assistant_page.py` 顶部的 `DOI_LIST_FILE` 变量，然后重新运行。

License

MIT